Это задание также относится к отредактированной таблице retail. Стартовый набор признаков все тот же, что и в последних экспериментов. Прочитай описание алгоритма и выполни все в точности.

Алгоритм long_grid_search

Этот алгоритм будет действовать итеративно, улучшая модель до тех пор, пока это возможно. Изначально он работает со всеми признаками, и исследует их на значимость, а также, на то, влияет ли значение соответствующего признаку параметра на качество модели. Изначально все признаки объявляются значимыми и изменяемыми, в ходе работы часть признаков станет незначимыми, или неизменными. Обратный переход невозможен: если признак отнесли на некотором шагу алгоритма к незначимому, он не участвует в дальнейших обучениях. Если признак отнесли на некотором шагу алгоритма к неизменным, значение его параметра фиксируется навсегда.

Ход алгоритма отмечай в таблице long_grid_search.csv. Сначала запиши в нее названия (НЕ ЗНАЧЕНИЯ) всех признаков. Затем после каждого эксперимента отмечай в таблице, какие признаки остались значимыми и изменяемыми (значимый и изменяемый - метка 2, значимый, но неизменяемый -- метка 1, незначимый -- метка 0), и какие для них на данный момент оптимальные значения параметров. Столбцы должны соответствовать экспериментам, строки -- признакам.

Эксперимент 1. (Сеточный поиск)

Для каждой группы фич будет проведен эксперимент. необходимо построить группу моделей. Модели группы будут обучены по всем вышеуказанным признакам, но с разными параметрами. Параметры всех групп, кроме выделенной исследуемой, будут выбраны как среднее из области определения параметра. Для параметра исследуемой группы будет рассмотрено 10 значений, для каждого из них обучаем отдельную модель.

Эксперимент 2. (Фильтрация)

Сначала выбираем оптимальные (выбранные экспериментально на предыдущем шаге) значения всех параметров. Для этих параметров обучаем модель на всех признаках . Далее для каждой группы фич строим одну отдельную модель: эта модель обучается на всех фичах, кроме фич указанной группы. Параметры все еще берем оптимальные. Если после удаления группы признаков модель не стала хуже, считаем этот признак незначимым. (Считаем, что модель стала хуже, если ROC уменьшилось хотя бы на 0.01, или если ROC изменилась менее чем на 0.01, а PR уменьшилось хотя бы на 0.005)

Эксперимент 3. (Сеточный поиск - 2)

Далее рассматриваются только значимые признаки -- те, после удаления которых модель стала хуже. Каждому из оставшихся признаков присвоим новый, каждому отдельный, параметр, и для каждого признака построим отдельную модель. Для параметра исследуемого признака рассмотрим 10 значений, выбранных через равные промежутки из области значений. Остальные параметры будут установлены как среднее из области значений. Таким образом, для каждого параметра будет выбрано оптимальное значение. Создаем таблицу long_alg_exp_3.csv, в ней будут все значимые признаки и оптимальные значения их параметров. Отслеживаем влияние параметров:

если все изменения параметра не сделали модель лучше, назовем соответствующий признак неизменным, и на все оставшиеся эксперименты зафиксируем ему значение -- среднее по промежутку значений, рассматриваемого в этом сеточном поиске. Остальные признаки (и соответствующие им параметры) назовем изменяемыми.

Эксперимент 4. (Фильтрация-2)
Сначала выбираем оптимальные (выбранные экспериментально на предыдущем шаге) значения всех параметров. Для этих параметров обучаем модель на всех признаках . Далее для каждой фичи строим одну отдельную модель: эта модель обучается на всех фичах, кроме указанной. Параметры все еще берем оптимальные. Если после удаления признака модель не стала хуже, считаем этот признак незначимым. (Считаем, что модель стала хуже, если ROC уменьшилось хотя бы на 0.01, или если ROC изменилась менее чем на 0.01, а PR уменьшилось хотя бы на 0.005).

Далее необходимо выполнять попеременно сеточный поиск и фильтрацию. После каждой фильтрации (включая фильтрацию-2) незначимые признаки будут удаляться из рассмотрения. Они НЕ ДОЛЖНЫ использоваться для обучения всех последующих моделей. Что касается сеточного поиска, он будет проводиться только по параметрам изменяемых и значимых признаков (на каждой итерации какие-то из признаков могут стать неизменными). Промежуток сеточного поиска будет меняться: на каждой новой итерации сеточного поиска длина промежутка будет уменьшаться вдвое по сравнению с предыдущей итерацией. То есть, сеточный поиск-k будет использовать длину промежутка n/(2^(k - 1)), где n - изначальная длина промежутка. Середина рассматриваемого промежутка всегда будет устанавливаться на найденное ранее оптимальное значение параметра. Если рассматриваемый промежуток вылезает за границу области значений параметра (заданную едино для всех параметров как (7, Y)), необходимо вместо всего промежутка рассматривать лишь его пересечение с областью значений. Число рассматриваемых значений параметров в каждом сеточном поиске будет одинаковым -- 10. Необходимо проводить попеременно сеточный поиск и фильтрацию до тех пор, пока модель не перестанет улучшаться, или пока длина промежутка сеточного поиска не станет меньше 10: точнее, после выполнения очередной итерации “сеточный поиск + фильтрация” мы сравниваем лучшую модель этой итерации с лучшей моделью предыдущей итерации, и если 3 итерации подряд улучшений модели не происходит, останавливаем работу.
Затем, после всех итераций сеточного поиска и фильтраций, необходимо обучить финальную модель по всем тем признакам, которые на момент последней итерации все еще считаются значимыми, с найденными для них оптимальными значениями параметров.
Пояснение:
Фактически, мы итеративно улучшаем все параметры, пока это улучшает качество модели, когда изменения параметра перестают влиять на качество модели, мы его фиксируем. И так же, итеративно, фильтруем признаки, работая с ними ровно до того момента, когда они перестают иметь влияние на модель.

Мне может понадобиться запустить эту модели на другом устройстве. Выгрузи на https://github.com/JoannaEK/RecSyS все файлы, необходимые для этого.
В названии файлов должно быть long_grid_search_res

Выгрузи таблицу long_grid_search.csv на репозиторий
https://github.com/JoannaEK/RecSyS