Выполни алгоритм short_stohastic_search не на полной отредактированной retail, а на подвыборках. Посчитай для каждого пользователя среднее число покупок AVG(visitor) за все время. Назначь для каждого пользователя visitor отдельное значение вероятности добавления его в подвыборку таким образом, чтоб эта вероятность была тем больше, чем ближе AVG(visitor) к медианному значению AVG(visitor) по всем пользователям. В каждую выборку должны попасть примерно 1% всех пользователей из отредактрованной retail.
Сделай три подвыборки пользователей из отредактрованной retail, на каждой вычисли по алгоритму short_stohastic_search значимые признаки и их оптимальные параметры. Получится три набора значимых признаков и три набора соответствующих параметров. Обучи 4 новых модели на полном датасете: первые три будут обучаться по этим самым наборам, для четвертой составь из этих трех новый набор: в него попадут только те признаки, которые есть во всех трех, а оптимальные значения параметров этих признаков вычисли как среднее значений соответствующих параметров из наборов. Эти 4 модели опиши в таблице и выложи на все тот же репозиторий.